Nombre: Ivan Arturo Cabrera Bravo	**Matrícula**: AL07182813
Nombre del curso: Gestión de Proyectos de Inteligencia Artificial.	**Nombre del profesor:** Luis Ariel Vázquez Piña.
Módulo: 2	**Actividad 4**.
Fecha: 11 de Octubre2026	

Bibliografía:

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. En Proceedings of NAACL-HLT 2019 (pp. 4171–4186). https://doi.org/10.18653/v1/N19-1423

Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., & Stoyanov, V. (2019). RoBERTa: A robustly optimized BERT pretraining approach. arXiv. https://arxiv.org/abs/1907.11692

Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). DistilBERT, a distilled version of BERT: Smaller, faster, cheaper and lighter. arXiv. https://arxiv.org/abs/1910.01108

Wang, A., Singh, A., Michael, J., Hill, F., Levy, O., & Bowman, S. R. (2018). GLUE: A multi-task benchmark and analysis platform for natural language understanding. arXiv. https://arxiv.org/abs/1804.07461

Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., Davison, J., Shleifer, S., von Platen, P., Ma, C., Jernite, Y., Plu, J., Xu, C., Le Scao, T., Gugger, S., ... Rush, A. M. (2020). Transformers: State-of-the-art natural language processing. En Proceedings of EMNLP 2020: System Demonstrations (pp. 38–45). https://doi.org/10.18653/v1/2020.emnlp-demos.6

Hugging Face. (s. f.). Transformers documentation. https://huggingface.co/docs/transformers/index

Hugging Face. (s. f.). GLUE dataset. https://huggingface.co/datasets/nyu-mll/glue

Actividad 4. Evaluación comparativa de modelos Transformer preentrenados mediante Hugging Face

Introducción y planteamiento del problema

La clasificación automática de textos se ha convertido en una opción práctica para explorar grandes volúmenes de comentarios. En un entorno de atención al cliente, una herramienta de este tipo podría ayudar a identificar mensajes con tono favorable o desfavorable y ofrecer una primera señal para su revisión. Sin embargo, una predicción correcta en un conjunto de prueba no garantiza que el mismo comportamiento se mantenga al cambiar de contexto, idioma o población.

Esta actividad parte de una pregunta concreta: ¿qué modelo preentrenado ofrece un equilibrio razonable entre calidad de clasificación, rapidez de inferencia y tamaño, cuando los tres se evalúan bajo las mismas condiciones? En lugar de seleccionar una arquitectura por su popularidad, se contrastaron resultados observables en una GPU Tesla T4 de Google Colab.

El objetivo no fue entrenar desde cero ni construir un clasificador de áreas de atención. Se trató de implementar y comparar tres checkpoints ya ajustados para polaridad de sentimiento, medir su comportamiento y documentar una decisión técnica que pueda ser discutida y reproducida.

Objetivo general

Comparar el desempeño de DistilBERT, BERT y RoBERTa sobre una muestra etiquetada de SST-2, utilizando métricas de clasificación y eficiencia para fundamentar la elección de un modelo en un prototipo académico.

Objetivos específicos

Identificar los componentes de Hugging Face utilizados; justificar la elección de tres modelos comparables; ejecutar inferencia reproducible con GPU; calcular métricas globales y por clase; contrastar errores, latencia y número de parámetros; reconocer las limitaciones del experimento y documentar su reproducción en GitHub.

Ecosistema Hugging Face y criterios de selección

Hugging Face reúne repositorios de modelos, tokenizadores, datasets y herramientas que facilitan utilizar arquitecturas Transformer sin reconstruir sus componentes. En el proyecto, Transformers permite cargar tokenizadores y modelos de clasificación; Datasets aporta SST-2; PyTorch ejecuta inferencia en GPU y scikit-learn calcula las métricas. El Hub actúa como fuente de checkpoints públicos, cuya disponibilidad y condiciones de uso deben revisarse antes de una aplicación comercial.

La comparación se limitó a modelos entrenados para una misma tarea binaria y con salida interpretable como sentimiento negativo o positivo. Este criterio evita contrastar arquitecturas destinadas a tareas distintas. También se consideraron el tamaño, la disponibilidad pública, la posibilidad de inferencia en Colab y la facilidad para replicar la evaluación.

Modelo	Checkpoint evaluado	Enfoque de comparación
DistilBERT	distilbert/distilbert-base-uncased-finetuned-sst-2-english	Modelo compacto; referencia de eficiencia
BERT	textattack/bert-base-uncased-SST-2	Arquitectura base; referencia de desempeño
RoBERTa	textattack/roberta-base-SST-2	Variante robustamente preentrenada; alternativa de precisión

DistilBERT reduce el tamaño de una arquitectura tipo BERT mediante destilación, lo que lo vuelve atractivo cuando existen restricciones de recursos. BERT constituye un punto de referencia ampliamente estudiado. RoBERTa introduce cambios en la estrategia de preentrenamiento de la familia BERT. Estas diferencias justifican la comparación, pero no anticipan por sí mismas cuál será el mejor modelo para todos los casos.

Diseño metodológico y preparación de datos

Se utilizó el conjunto GLUE/SST-2, dividido en ejemplos de sentimiento positivo y negativo provenientes de reseñas cinematográficas en inglés. El subconjunto de validación contiene 872 observaciones: 444 positivas y 428 negativas. A partir de este conjunto, el notebook seleccionó 100 ejemplos por clase mediante muestreo estratificado y una semilla fija, para un total de 200 registros.

El balanceo responde a un propósito metodológico: que cada clase tenga el mismo peso en la evaluación y que las diferencias entre modelos no se expliquen por una presencia mayoritaria de una etiqueta. Esto facilita interpretar el recall de ambas clases y la métrica F1 macro. Al mismo tiempo, modifica la proporción original y no representa necesariamente la frecuencia real de opiniones positivas y negativas en una operación de atención al cliente.

Los tres modelos recibieron exactamente las mismas 200 observaciones. Se fijó una longitud máxima de 128 tokens y se procesaron lotes de 16 textos. No hubo ajuste de pesos ni separación adicional para entrenamiento: se evaluaron checkpoints preentrenados y ya afinados para SST-2. Por esa razón, las cifras deben entenderse como evaluación de inferencia y no como evidencia de un proceso de entrenamiento propio.

Controles de reproducibilidad

El notebook registra el dispositivo de cómputo, define semillas, guarda la muestra y produce archivos con métricas y predicciones. Además, instala dependencias y comprueba su consistencia con pip check. En la ejecución recibida se utilizó una Tesla T4 y la verificación de dependencias finalizó con “No broken requirements found”. Las mediciones de tiempo dependen de la carga de Colab y de las versiones concretas del entorno; conviene conservar el notebook ejecutado junto con los resultados exportados.

Implementación técnica en Google Colab

La implementación se organizó por etapas: preparación del entorno, carga y auditoría de datos, descarga de tokenizadores y modelos, inferencia, evaluación comparativa y auditoría estadística. Para cada arquitectura se recuperó su configuración de etiquetas y se transformaron las salidas numéricas en las dos clases de interés. Se calculó la matriz de confusión y se guardaron las predicciones para analizar desacuerdos.

La inferencia se realizó con PyTorch en GPU. La medición de latencia incluyó tokenización y transferencia de datos, con calentamiento previo y sincronización CUDA para reducir errores de medición asíncrona. En la auditoría final se registraron cinco pasadas completas; la cifra reportada es la mediana aproximada por texto cuando se procesan lotes de 16, no el tiempo de respuesta de una solicitud individual aislada.
Una decisión relevante fue evitar credenciales en el repositorio. Los modelos y datos públicos no exigieron autenticación; el notebook permite utilizar un token como secreto de Colab cuando se requiera. Esto reduce el riesgo de publicar información sensible por accidente.

Resultados cuantitativos de la ejecución

Las cifras de esta sección se transcribieron de las salidas del notebook final ejecutado.

Las métricas se calcularon sobre 200 registros comunes a los tres modelos; por tanto, sus diferencias son comparables dentro de este experimento, aunque no equivalen a una evaluación de producción.

Métrica	DistilBERT	BERT	RoBERTa
Accuracy	87.50 %	92.00 %	92.50 %
Precision macro	87.59 %	92.02 %	92.61 %
Recall macro	87.50 %	92.00 %	92.50 %
F1 macro	87.49 %	92.00 %	92.50 %
Latencia mediana por texto	1.46 ms	4.07 ms	2.97 ms
Parámetros	66.96 M	109.48 M	124.65 M

En accuracy, RoBERTa obtuvo 185 aciertos; BERT, 184; y DistilBERT, 175. La distancia entre RoBERTa y BERT fue, por tanto, de un solo registro. Esta observación es más informativa que presentar una diferencia porcentual sin considerar el tamaño de muestra.

Matrices de confusión

Modelo	Negativo correcto	Negativo como positivo	Positivo como negativo	Positivo correcto
DistilBERT	85	15	10	90
BERT	91	9	7	93
RoBERTa	95	5	10	90

Las matrices muestran un patrón relevante. RoBERTa identificó correctamente 95 de los 100 ejemplos negativos, más que BERT y DistilBERT; sin embargo, recuperó 90 de los 100 positivos, por debajo de BERT. BERT presentó un comportamiento más equilibrado entre las dos clases. Esto significa que la elección podría cambiar si el costo de no detectar un comentario negativo fuera especialmente elevado o si la prioridad fuera preservar la detección de comentarios positivos.

Precisión, recall y F1 por clase

Modelo / clase	Precision	Recall	F1
DistilBERT / negativa	0.895	0.850	0.872
DistilBERT / positiva	0.857	0.900	0.878
BERT / negativa	0.929	0.910	0.919
BERT / positiva	0.912	0.930	0.921
RoBERTa / negativa	0.905	0.950	0.927
RoBERTa / positiva	0.947	0.900	0.923

Accuracy resume la proporción total de aciertos; precision indica qué parte de las predicciones de una clase fueron correctas; recall representa la fracción de ejemplos reales de esa clase recuperados; F1 combina precision y recall mediante su media armónica. Se eligió F1 macro como referencia principal porque asigna el mismo peso a las dos clases, independientemente de su tamaño.

Eficiencia, incertidumbre y análisis de errores

DistilBERT fue el más rápido, con una mediana de 1.46 ms por texto, y también el más pequeño. Su F1 macro fue aproximadamente cinco puntos inferior al de RoBERTa. BERT alcanzó una calidad próxima a RoBERTa, pero en esta ejecución presentó mayor latencia. RoBERTa ocupó más parámetros que BERT y, pese a ello, procesó los lotes con menor latencia mediana. Este resultado observado puede depender de la arquitectura, el entorno y la variación de mediciones; no implica que RoBERTa sea siempre más rápido en cualquier dispositivo.

La auditoría reportó intervalos de confianza de Wilson al 95 % para accuracy: DistilBERT [0.822, 0.914], BERT [0.874, 0.950] y RoBERTa [0.880, 0.954]. Los intervalos bootstrap exploratorios de F1 macro fueron, respectivamente, [0.825, 0.920], [0.880, 0.955] y [0.889, 0.960]. Existe un solapamiento considerable, especialmente entre BERT y RoBERTa. No corresponde afirmar que la diferencia de 0.5 puntos sea estadísticamente concluyente.

El notebook identificó 20 observaciones en las que al menos dos modelos no coincidieron. Estas discrepancias merecen atención porque permiten estudiar expresiones ambiguas, construcciones irónicas o frases difíciles de clasificar. Sin una revisión manual documentada de cada texto no sería riguroso atribuir los desacuerdos a una causa específica. Para un proyecto posterior, convendría etiquetar los tipos de error y analizar si ciertos patrones lingüísticos concentran los fallos.

Selección y justificación del modelo

La regla académica definida en el notebook consideró elegibles los modelos con F1 macro de al menos 0.85 y latencia inferior a 100 ms por texto. Entre aquellos situados a menos de 0.01 puntos de F1 del máximo, se eligió el de menor latencia. Los tres superaron los umbrales iniciales; BERT y RoBERTa quedaron dentro de la banda de desempeño próxima al máximo, y RoBERTa presentó menor latencia en esta ejecución. Por ello, la selección automática fue RoBERTa.

Esta elección es razonable para el prototipo, pero debe describirse como provisional. La ventaja de RoBERTa sobre BERT fue mínima en precisión y se observó en un único

subconjunto de 200 registros. En un escenario real también se deberían valorar memoria, concurrencia, costo de infraestructura, frecuencia de actualización, robustez por subgrupos y necesidades de explicabilidad. DistilBERT seguiría siendo una opción competitiva para dispositivos o servicios con presupuestos de cómputo ajustados.
En consecuencia, la recomendación no es “RoBERTa es universalmente superior”, sino “RoBERTa fue la opción favorecida por los criterios y mediciones de esta prueba”. La distinción evita convertir un resultado experimental limitado en una conclusión que exceda la evidencia.

Riesgos, limitaciones y acciones de mejora

Validez externa y lenguaje

SST-2 contiene reseñas cinematográficas en inglés. Los comentarios de clientes de una institución financiera pueden incluir español, abreviaturas, errores ortográficos, solicitudes operativas y expresiones de urgencia. Además, identificar sentimiento no equivale a asignar una solicitud a un departamento ni a determinar su prioridad. Antes de cualquier uso real se necesitaría un dataset representativo del dominio, etiquetas definidas con el negocio y validación independiente.

Errores y supervisión humana

Una predicción negativa puede resultar útil para priorizar una revisión, pero no debería activar automáticamente una decisión sensible. Los falsos positivos generarían revisiones innecesarias y los falsos negativos podrían ocultar señales de insatisfacción. Conviene incorporar revisión humana, monitoreo de errores, umbrales por tipo de riesgo y mecanismos para corregir predicciones.

Privacidad, licencias y mantenimiento

Este ejercicio empleó datos públicos y no requiere información privada de clientes. Para un piloto real serían indispensables políticas de minimización, control de acceso y tratamiento adecuado de datos personales. También se deberán verificar las licencias vigentes de cada checkpoint y del dataset directamente en sus fichas. Las dependencias deben mantenerse documentadas y las métricas recalcularse cuando cambien el modelo, los datos o la infraestructura.

Plan de evolución del prototipo

Una siguiente fase podría evaluar textos reales debidamente anonimizados, incorporar español y establecer un conjunto de prueba independiente. Después se medirían latencias bajo carga concurrente, consumo de memoria y estabilidad en diferentes GPU o CPU. Solo entonces tendría sentido plantear objetivos operativos, como tiempos máximos de respuesta, niveles mínimos de recall para mensajes críticos y frecuencia de revisión del modelo.

Conclusiones y reflexión académica

La actividad permitió comprobar que la selección de un modelo no debería reducirse a escoger la cifra de accuracy más alta. Aunque RoBERTa obtuvo el mejor resultado global de esta prueba, BERT se mantuvo muy cerca y DistilBERT mostró una ventaja importante en velocidad y tamaño. Las matrices de confusión también dejaron claro que dos modelos con puntuaciones similares pueden equivocarse en clases distintas.
El hallazgo más importante es metodológico: cuando todos los modelos se evalúan con los mismos registros, parámetros de inferencia y métricas, la discusión técnica se vuelve más transparente. También aprendimos que el rendimiento observado en un dataset académico no sustituye la validación con datos del contexto real. En ese sentido, el valor del prototipo está tanto en sus resultados como en la posibilidad de reproducirlos, examinarlos y reconocer sus límites.

Para este ejercicio se recomienda RoBERTa bajo la regla de selección establecida, con la advertencia de que la diferencia respecto a BERT es pequeña y no concluyente. Antes de trasladar la solución a atención al cliente sería necesario redefinir la tarea, evaluar datos en español y comprobar el impacto de los errores sobre las decisiones operativas.